ANÁLISIS DEL CONTRASTE TUMOR FRENTE A NORMAL

Ana Elena Fernández Fernández, Cuarto curso del Grado en Bioquímica, Asignatura de Bioinformática y Análisis Genómico, Tarea02

1. PLOT DE DISPERSION

En el gráfico de dispersión (*Figura 1)* generado por PyDESeq2 (Love et al., 2014; Muzellec et al., 2023) se puede observar que los genes con poca expresión son más variables, es decir, tienen más dispersión (la línea roja sube); mientras que los genes muy expresados tienen menor variabilidad (la línea roja se estabiliza).

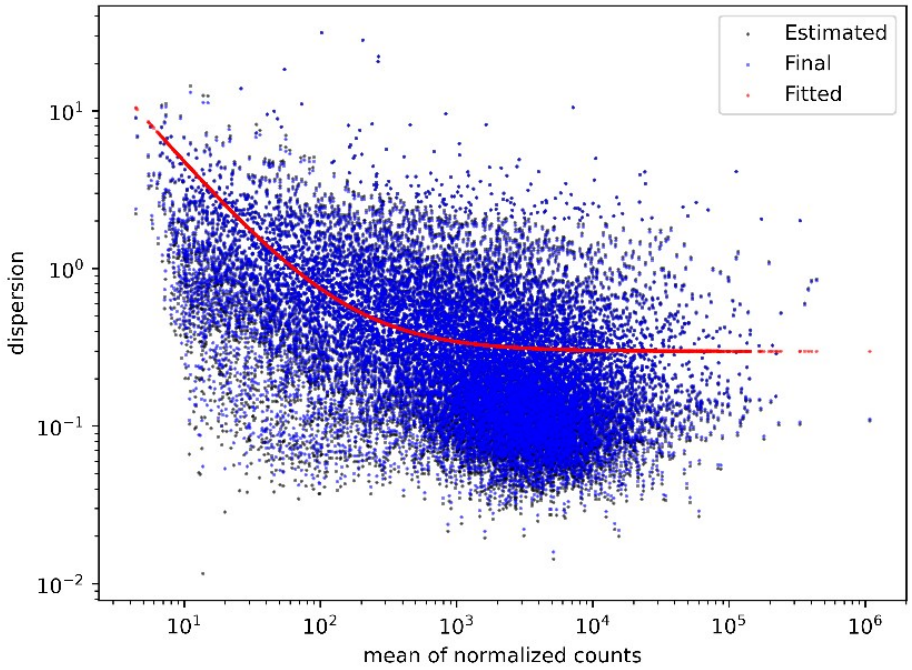


Figura 1: Gráfico de dispersión generado por PyDESeq2 (*plot_dispersion.png*), donde cada punto es un gen. El eje X representa la media de los conteos normalizados de cada gen (expresión génica corregida según el tamaño de la librería), mientras que el eje Y representa la dispersión de cada gen (variabilidad de los conteos entre muestras), ambas en escala logarítmica. La línea roja representa la tendencia (dispersión esperable para un gen con ese nivel de expresión).

2. MA PLOT

En el MA plot generado tras la normalización de PyDESeq2 (*Figura 2)*, se observa que la mayoría de los genes se distribuyen alrededor de log2FoldChange = 0, tanto por encima (genes sobreexpresados) como por debajo (genes subexpresados). Esto indica que no existe un desplazamiento global evidente hacia una mayor expresión en ninguna de las dos condiciones, sugiriendo una normalización adecuada.

Además, cabe destacar la presencia de dos genes con un log2Fold Change elevado que se alejan bastante de la línea horizontal. Estos genes se encuentran sobreexpresados en el tumor, y se observarán también en el Volcano Plot (*Figura 3*).

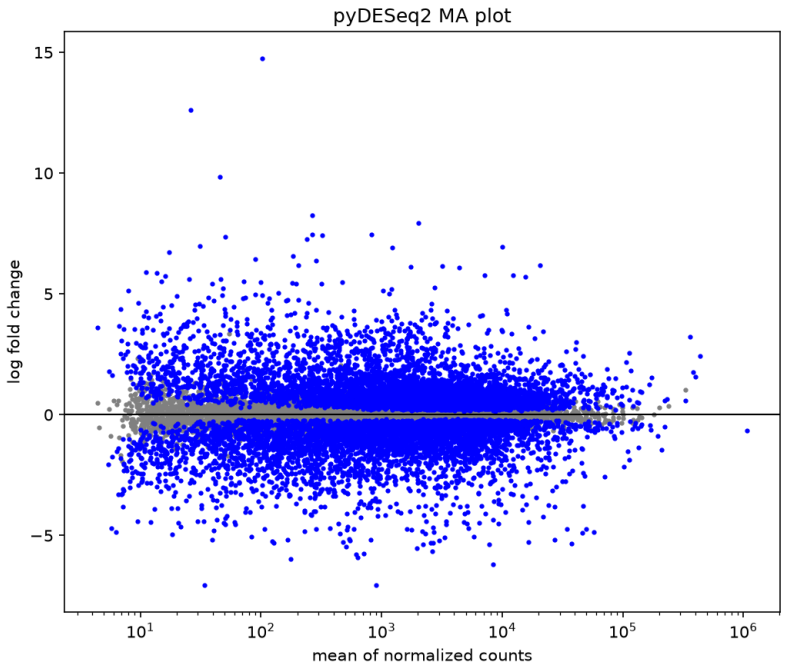


Figura 2: MA plot del contraste tumor frente a normal tras normalización de PyDESeq2 (*plot_MA.png*). Cada punto corresponde a un gen; el eje X indica abundancia media y el eje Y el cambio de expresión (log2FoldChange). Los puntos azules señalan los genes con un cambio de expresión significativo.

3. VOLCANO PLOT Y CRITERIOS ESTADÍSTICOS

La herramienta PyDESeq2 compara la expresión génica en la condición de estudio (tejido mamario tumoral) respecto a la condición de referencia (tejido normal adyacente), ajustando por el efecto técnico de placa; y devuelve una serie de parámetros.

En primer lugar, pyDESeq2 calcula el Fold Change (FC), es decir, el ratio de la expresión génica media en la condición de estudio respecto a la de referencia, que permite filtrar los cambios de expresión génica que consideraremos relevantes desde el punto de vista biológico. En nuestro caso, se escogió el umbral |log2(FC)| = 1, que corresponde a cambios de expresión superiores al doble o inferiores a la mitad entre ambas condiciones.

En segundo lugar, PyDESeq2 realiza un test estadístico basado en una binomial negativa con la igualdad de la expresión media como hipótesis nula y su diferencia como hipótesis alternativa. No obstante, dado que se realizan múltiples contrastes dado el alto número de genes, se obtienen demasiados falsos positivos. Para solucionarlo, pyDESeq2 aplica una corrección del p-valor por el método de Benjamini-Hochberg (Benjamini & Hochberg, 1995), devolviendo un p-valor ajustado que controla la tasa de falsos descubrimientos (FDR). Entonces, sobre el p-valor ajustado se establece un umbral de 0.05, ya que se considera un valor adecuado para estudios biológicos y no excesivamente restrictivo.

Atendiendo a estos dos criterios se seleccionan los resultados de la siguiente manera:

- Genes estadísticamente significativos: p-adj < 0.05
- Genes diferencialmente expresados: $|\log_2 FC| > 1$ y p-adj < 0.05

- Genes sobreexpresados en tumor (*Up*): log2(FC) > 1 y p-adj < 0.05
- Genes subexpresados en tumor (*Down*): log2(FC) < (-1) y p-adj < 0.05

A partir de esta selección de los genes, se dibuja el Volcano Plot (*Figura 3*). En este gráfico, los genes significativos se sitúan por encima de la línea discontinua horizontal (umbral del p-valor ajustado); mientras que los genes diferencialmente expresados se sitúan a la izquierda (genes *down*-regulated) y a la derecha (genes *up*-regulated*)* de las dos líneas discontinuas verticales, que representan los umbrales del log2 FC en cada caso.

Se etiquetan los 10 genes con mayor significancia estadística en cada categoría, los cuales se comentarán a continuación y quedan recogidos en la *Tabla 1* y *Tabla 2*, y en la *Figura 4,* donde se representan según su log2 FC.

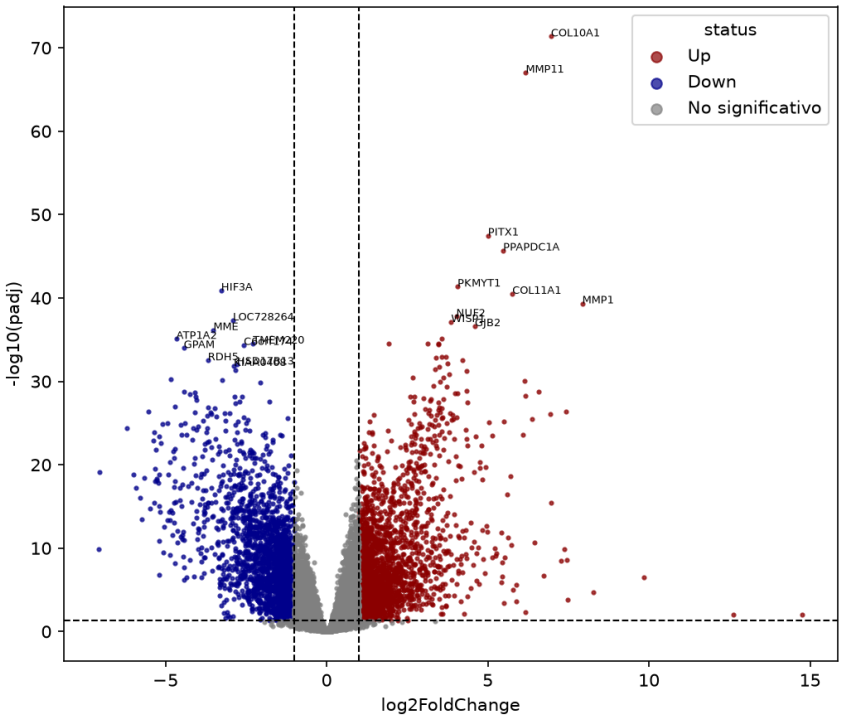


Figura 3: Volcano plot del contraste tumor frente a normal (*plot_volcano.png*). Cada punto representa un gen; el eje X muestra la magnitud del cambio (log2FoldChange) y el eje Y la evidencia estadística (-log10(padj)). Las líneas discontinuas marcan los umbrales utilizados: $|log_2 FC| > 1$ y p-adj < 0.05.

El gen más destacado por su significación estadística es **COL10A1** (Colágeno Tipo X Cadena Alfa 1) con un valor de log2FC de 6.96 y un p-valor ajustado de 4.26e-72, por lo que se sobreexpresa de manera significativa en el tejido tumoral. Este gen, al igual que **COL11A1** (Colágeno Tipo XI Cadena Alfa 1), también sobreexpresado, codifica para un tipo de colágeno. El colágeno es un componente importante de la matriz extracelular que participa en la reestructuración de esta, facilitando que las células epiteliales tumorales rompan las barreras fisiológicas e invadan el estroma circundante, permitiendo así la invasión tumoral local y la metástasis (Vargas et al., 2012), por lo que su sobreexpresión en el tejido tumoral resulta coherente.

gene_id	log2FoldChange	padj
COL10A1	**6.96**	**4.26e-72**
MMP11	6.18	9.31e-68
PITX1	5.00	3.22e-48
PPAPDC1A	5.48	2.01e-46
PKMYT1	4.06	4.22e-42
COL11A1	5.76	3.16e-41
MMP1	7.93	4.46e-40
NUF2	4.02	1.64e-38
WISP1	3.86	7.70e-38
GJB2	4.60	2.40e-37

Tabla 1: Genes sobreexpresados en el tumor con mayor significancia (*top10_up_genes.tsv*). El gen COL10A1 es el gen más destacado (*top_gene_context.txt).*

gene_id	log2FoldChange	padj
HIF3A	-3.27	1.27e-41
LOC728264	-2.91	4.81e-38
MME	-3.51	7.01e-37
ATP1A2	-4.67	7.93e-36
TMEM220	-2.29	2.90e-35
C6orf174	-2.57	4.30e-35
GPAM	-4.43	1.00e-34
RDH5	-3.69	2.98e-33
HSD17B13	-2.79	9.52e-33
KIAA0408	-2.88	1.40e-32

Tabla 2: Genes subexpresados en el tumor con mayor significancia estadística (*top10_down.genes.tsv).*

Por otra parte, otro de los genes *up*-regulated destacado es **MMP11** (Metaloproteinasa 11 de la matriz), que codifica para una metaloproteinasa que participa en la remodelación de la matriz extracelular, promoviendo activamente la invasión tumoral y la metástasis. MMP11 favorece, además, un microambiente tumoral inmunosupresor al reducir la presencia de linfocitos T, linfocitos B y linfocitos infiltrantes del tumor (Kim et al., 2021). De hecho, este gen se considera como diana terapéutica, pues se ha comprobado que la proteína inhibe la degradación de la proteína Smad2 en la vía de señalización de TGF-β, promoviendo el desarrollo del cáncer de mama (Zhuang et al., 2021).

Asimismo, el gen con mayor sobreexpresión en el tejido tumoral es **MMP1**, con un log2FC de 7.93 y un p-valor ajustado de 4.46e-40. Este gen también pertenece a la familia de las metaloproteinasas de la matriz (MMP, *matrix metalloproteinase)*, por lo que, probablemente, tenga un papel similar a MMP11 en la progresión tumoral.

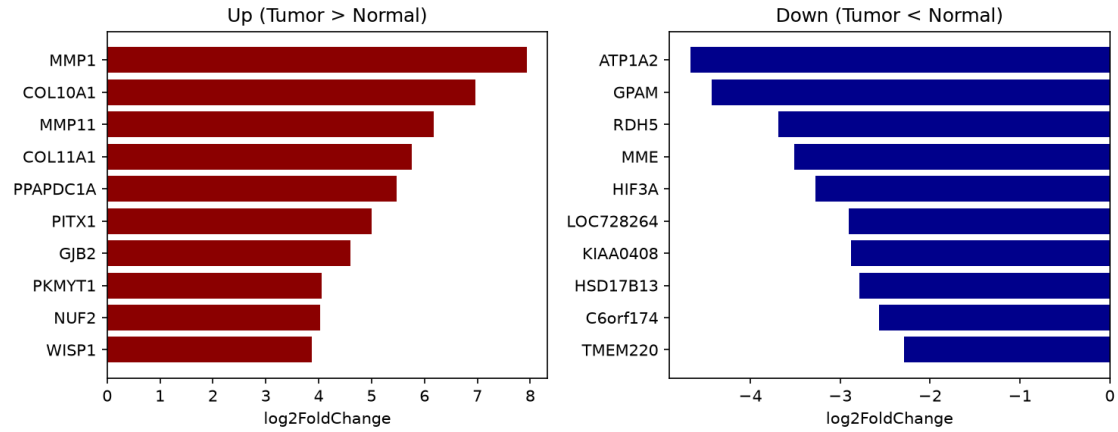


Figura 4: Gráfico de barras horizontales que representa los 10 genes más significativos en el contraste tumor frente a normal ordenados según su log2FC (*plot_top10_genes.png*). El panel izquierdo muestra genes sobreexpresados en tumor (*up*) y el derecho genes con menor expresión relativa en tumor (*down*). El eje X representa el log2 FC: valores positivos indican mayor expresión en tumor y valores negativos mayor expresión en tejido normal.

En cuanto a los genes con menor expresión relativa en el tumor, se destacan los siguientes:

- **MME** *(Membrane Metalloendopeptidase*): Codifica para una metalopeptidasa, que actúa como supresor de la vía de señalización JAK/STAT3, por lo que la disminución de sus niveles de expresión podría desencadenar una activación de dicha vía en los macrófagos y el consecuente cambio fenotípico hacia macrófagos M2 (inmunosupresores y protumorales), favoreciendo la invasión local y la metástasis (Zhu et al., 2024).
- **HIF3A**: Se trata de un miembro de la familia de factores inducibles por hipoxia (HIFs) que suele actuar como un regulador negativo de la respuesta a hipoxia. Por tanto, su subexpresión en el tejido tumoral sugiere la activación sostenida de la señalización por hipoxia en el tumor, favoreciendo la angiogénesis, la reprogramación metabólica hacia la glucólisis y la supervivencia en ambientes deficientes de oxígeno (Yazdani & Sirous, 2022).

4. ENRIQUECIMIENTO FUNCIONAL

El enriquecimiento en términos de ontología de genes (Aleksander et al., 2026) y rutas Reactome (Gillespie et al., 2022) permite dar sentido biológico a la lista de genes diferencialmente expresados, lo que nos permite averiguar qué mecanismos o procesos celulares están implicados en el tumor de mama estudiado.

4.1. Enriquecimiento *GO Biological Process*

En primer lugar, el enriquecimiento funcional para los genes sobreexpresados en el tumor *(Figura 5)* muestra una señal muy consistente de proliferación, pues aparecen los términos GO *Mitotic Sister Chromatid Segregation* y *Mitotic Cell Cycle Phase*

Transition, que hacen referencia a la división celular, así como el término *DNA Metabolic Process,* que se corresponde con la replicación del ADN necesaria para la división celular.

Además, aparecen dos términos GO relacionados con la reparación de errores en el ADN: *DNA Damage Response y DNA Repair*. Esto se debe a que los tumores mamarios exhiben altas tasas de mutaciones somáticas debido a la alta tasa proliferativa, por lo que optan por aumentar la transcripción de la maquinaria de reparación del ADN para tratar de tolerar el estrés de replicación (Koboldt et al., 2012).

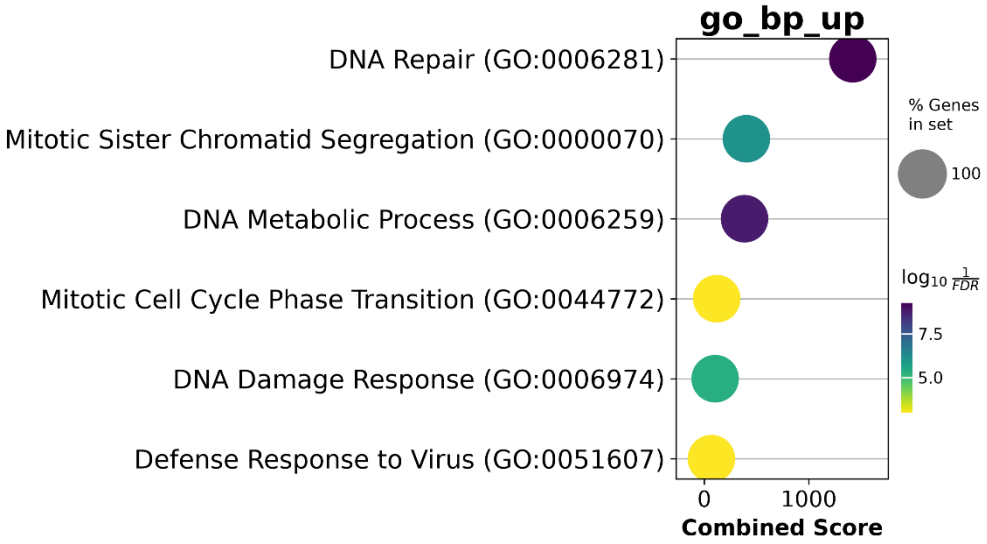


Figura 5: Enriquecimiento GO (*Biological Process*) en genes *up*-regulated con la librería *GSEApy* de Python (*plot_go_bp_up.png*). El color de los círculos refleja la significancia estadística del término (log10(1/FDR)): cuanto mayor es el valor, menor es el FDR (p-valor ajustado) y mayor es la significancia.

La presencia en la *Tabla 1* de genes ligados al ciclo celular y la mitosis corrobora esta observación:

- **PKMYT1** (*Membrane-associated tyrosine- and threonine-specific cdc2-inhibitory kinase*): actúa normalmente como un regulador negativo del ciclo celular para retrasar la entrada en mitosis y permitir la reparación del ADN.
- **NUF2** (*Kinetochore protein Nuf2*): implicado en la segregación de los cromosomas durante la mitosis.

Por otro lado, el enriquecimiento funcional para los genes subexpresados en el tumor *(Figura 6)* muestra términos GO relacionados con el metabolismo de los lípidos: *Fat Cell Differentiation, Fatty Acid Metabolic Process, Regulation of Cold-Induced Thermogenesis*, así como el término *Muscle Contraction.* Todo esto refleja los cambios que se producen en el tejido mamario al pasar a tumoral. En condiciones normales, el tejido mamario normal es rico en adipocitos y células mioepiteliales contráctiles, mientras que la masa tumoral invasiva pierde parte de los programas metabólicos y de diferenciación normales (Vargas et al., 2012).

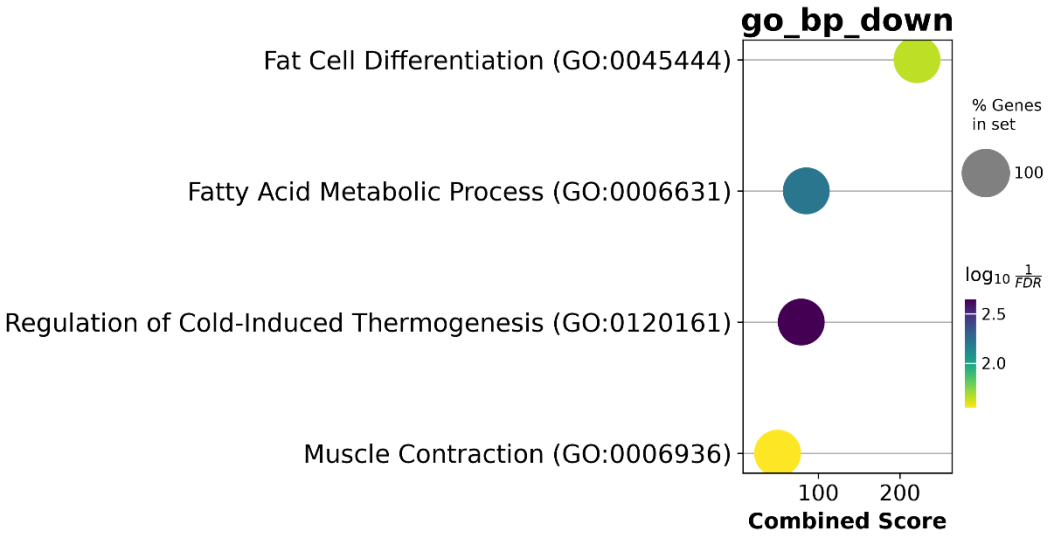


Figura 6: Enriquecimiento GO (*Biological Process*) en genes *down*-regulated con la librería *GSEApy* de Python (*plot_go_bp_down.png*). El color de los círculos refleja la significancia estadística del término (log10(1/FDR)): cuanto mayor es el valor, menor es el FDR (p-valor ajustado) y mayor es la significancia.

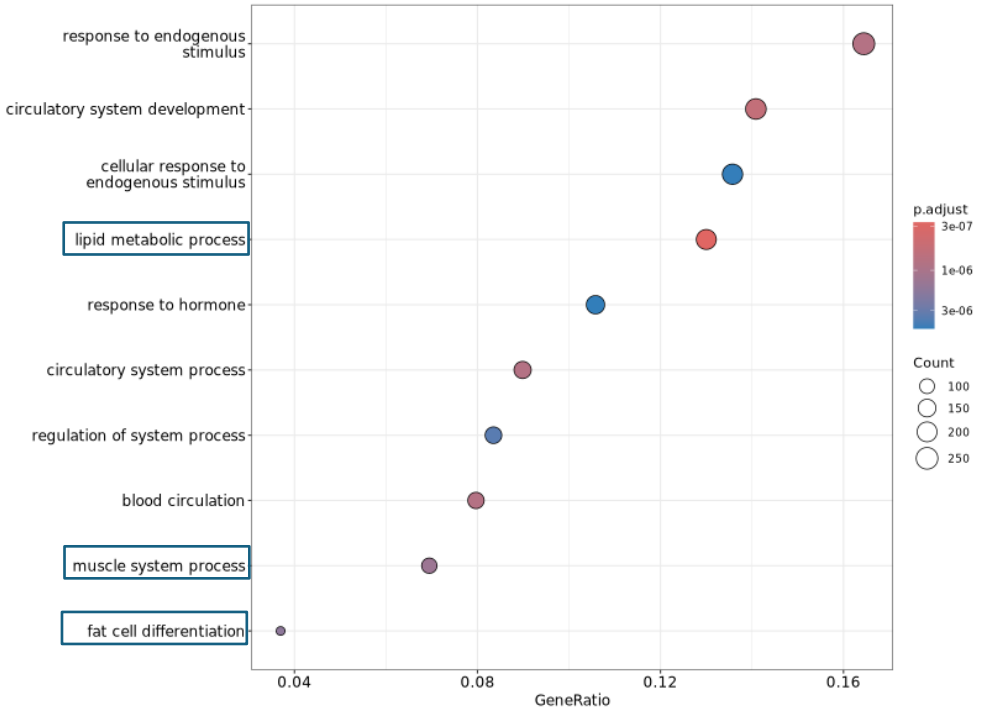


Figura 7: Enriquecimiento GO (*Biological Process*) en genes *down*-regulated con las librerías *ClusterProfiler* y *enrichplot* de R. El tamaño del círculo indica el número de genes de la lista de genes subexpresados incluidos en cada término GO, y el color refleja la significancia estadística del término: cuanto menor es el p-valor ajustado, más rosada es la tonalidad y mayor es la significancia.

En el dotplot generado con R para los genes *down*-regulated *(Figura 7)*, aparecen prácticamente los mismos términos GO: *Fat Cell Differentiation, Lipid Metabolic Process* y *Muscle System Process;* aunque aparecen además otros términos relacionados con la respuesta a estímulos endógenos y a hormonas. Esta diferencia puede deberse al uso de bibliotecas diferentes, y a las versiones de estas, pues pueden contener términos GO diferentes e incluir o no determinados genes. En Python se usa la biblioteca GSEApy (Fang et al., 2023) y en R se usan las librerías ClusterProfiler (Yu et al., 2012) y enrichplot (Guangchuang Yu, 2026).

4.2. Enriquecimiento Reactome

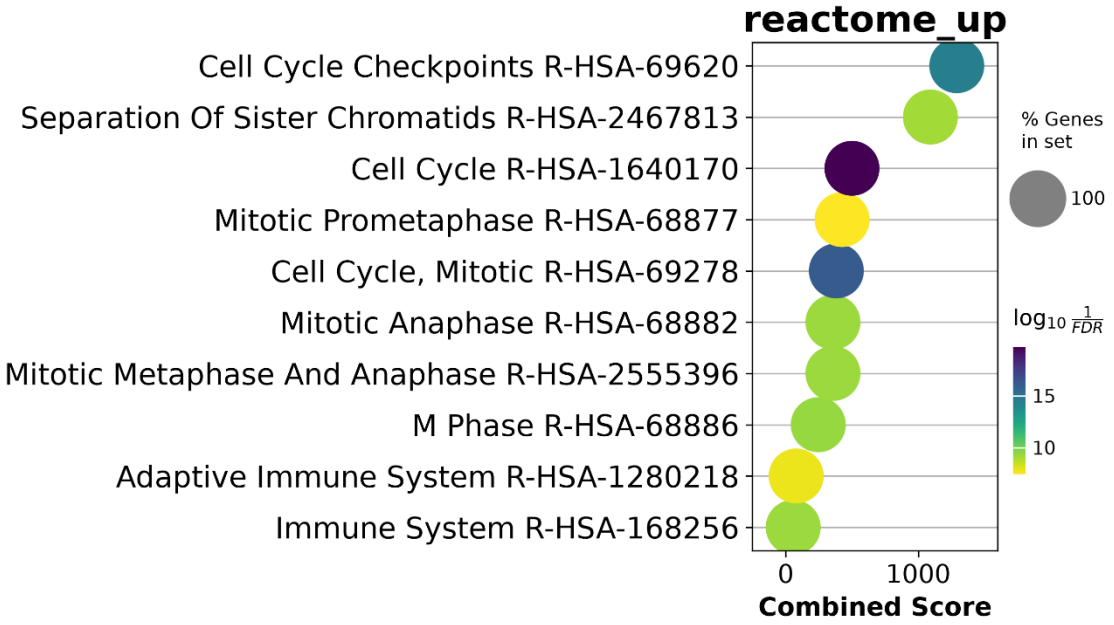


Figura 8: Enriquecimiento en rutas Reactome en genes *up*-regulated con la librería *GSEApy* de Python. El color de los círculos refleja la significancia estadística del término (log10(1/FDR)): cuanto mayor es el valor, menor es el FDR (p-valor ajustado) y mayor es la significancia.

En el enriquecimiento con Reactome para genes sobreexpresados en el tumor, se observa que las rutas principales se concentran en fase mitótica, ciclo celular y puntos de control (*checkpoints)* de este, lo cual se complementa con los términos GO *up*-regulated, y refuerza la interpretación de alta actividad proliferativa del tumor con respecto al tejido normal. Nuevamente, esta hipótesis queda evidenciada con la presencia de los genes PKMYT1 y NUF2 entre los genes sobreexpresados en el tumor.

Además, en la *Figura 8* aparece enriquecido el sistema inmunitario, pues el tumor podría atraer al sistema inmune tanto por la respuesta propia del hospedador como para reclutar macrófagos protumorales. Este enriquecimiento de la respuesta inmune puede verse reflejado en el término GO *Response to Virus* que aparecía en la *Figura 5.*

Finalmente, las rutas Reactome asociadas a los genes *down*-regulated en el tejido tumoral *(Figura 9)* incluyen el metabolismo, especialmente lipídico y la señalización mediada por proteínas G. Estas rutas apoyan la hipótesis anterior sobre la reducción relativa de los programas de diferenciación del tejido mamario normal en las células tumorales.

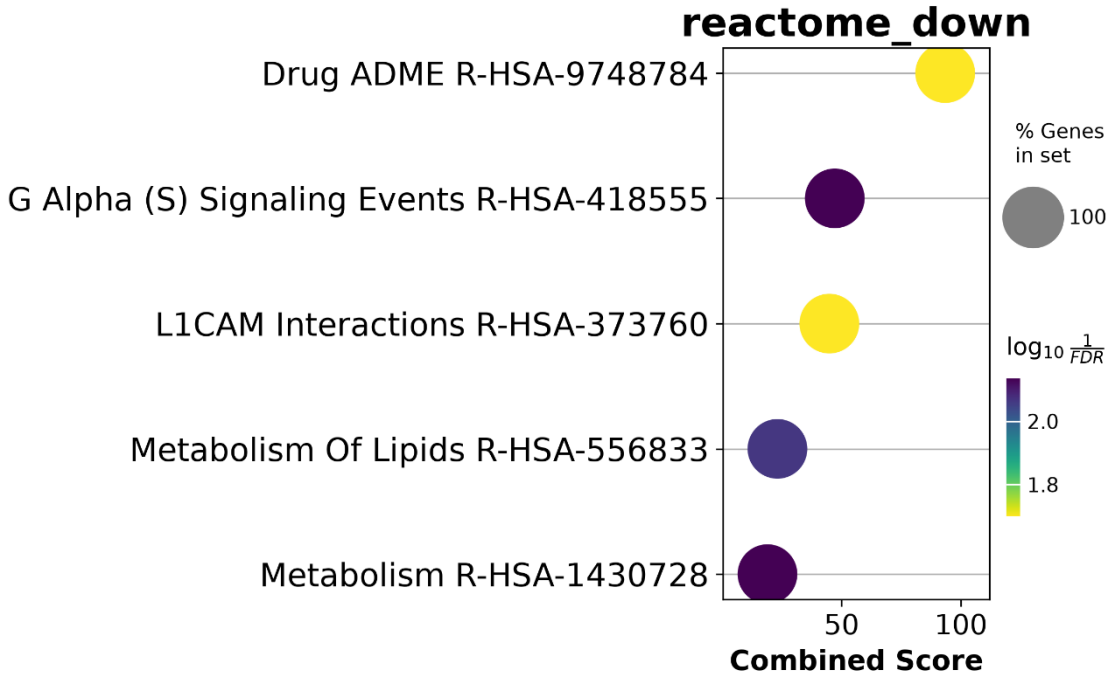


Figura 9: Enriquecimiento en rutas Reactome en genes *down*-regulated con la librería *GSEApy* de Python. El color de los círculos refleja la significancia estadística del término (log10(1/FDR)): cuanto mayor es el valor, menor es el FDR (p-valor ajustado) y mayor es la significancia.

5. CONCLUSIÓN

En conjunto, el análisis diferencial de expresión del contraste entre tejido tumoral de cáncer de mama y tejido normal adyacente (TCGA-BRCA) revela una serie de cambios moleculares compatibles con la progresión tumoral.

En primer lugar, destaca una firma proliferativa marcada en el tejido tumoral, respaldada por la sobreexpresión de genes como PKMYT1 y NUF2, relacionados con la regulación del ciclo celular y la segregación cromosómica. Esta observación coincide con el enriquecimiento de términos GO asociados a la mitosis, la replicación y la reparación del ADN, así como con las rutas Reactome de ciclo celular, fase mitótica y puntos de control.

En segundo lugar, la elevada expresión de COL10A1, COL11A1, MMP11 y MMP1 sugiere una remodelación de la matriz extracelular, compatible con un posible fenotipo invasivo.

Por otro lado, la disminución relativa de genes como ATP1A2, HIF3A y MME, junto con el enriquecimiento de procesos GO y rutas Reactome relacionados con el metabolismo lipídico sugiere una pérdida parcial de programas metabólicos y homeostáticos característicos del tejido mamario normal.

Por tanto, las evidencias obtenidas a nivel de gen, proceso biológico y vía molecular convergen en un modelo en el que el tejido tumoral presenta una mayor actividad proliferativa, cambios en la matriz extracelular y una reducción relativa de funciones metabólicas y de diferenciación propias del tejido normal. No obstante, se requiere una validación biológica experimental de los resultados.

6. REFERENCIAS

Aleksander, S. A., Balhoff, J. P., Carbon, S., Cherry, J. M., Ebert, D., Feuermann, M., Gaudet, P., Harris, N. L., Hill, D. P., Kalita, P., Lee, R., Mi, H., Moxon, S., Mungall, C. J., Muruganujan, A., Mushayahama, T., Sternberg, P. W., Thomas, P. D., Van Auken, K., … Westerfield, M. (2026). The Gene Ontology knowledgebase in 2026. *Nucleic Acids Research*, *54*(D1), D1779–D1792. https://doi.org/10.1093/nar/gkaf1292

Benjamini, Y., & Hochberg, Y. (1995). Controlling the False Discovery Rate: A Practical and Powerful Approach to Multiple Testing. *Journal of the Royal Statistical Society Series B: Statistical Methodology*, *57*(1), 289–300. https://doi.org/10.1111/j.2517-6161.1995.tb02031.x

Chen, E. Y., Tan, C. M., Kou, Y., Duan, Q., Wang, Z., Meirelles, G. V., Clark, N. R., & Ma'ayan, A. (2013). Enrichr: interactive and collaborative HTML5 gene list enrichment analysis tool. *BMC Bioinformatics*, *14*(1), 128. https://doi.org/10.1186/1471-2105-14-128

Fang, Z., Liu, X., & Peltz, G. (2023). GSEApy: a comprehensive package for performing gene set enrichment analysis in Python. *Bioinformatics*, *39*(1). https://doi.org/10.1093/bioinformatics/btac757

Gillespie, M., Jassal, B., Stephan, R., Milacic, M., Rothfels, K., Senff-Ribeiro, A., Griss, J., Sevilla, C., Matthews, L., Gong, C., Deng, C., Varusai, T., Ragueneau, E., Haider, Y., May, B., Shamovsky, V., Weiser, J., Brunson, T., Sanati, N., … D'Eustachio, P. (2022). The reactome pathway knowledgebase 2022. *Nucleic Acids Research*, *50*(D1), D687–D692. https://doi.org/10.1093/nar/gkab1028

Guangchuang Yu, C.-H. G. (2026). *enrichplot: Visualization of Functional Enrichment Result* (R package version 1.32.1). https://doi.org/doi:10.18129/B9.bioc.enrichplot

Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D., Wieser, E., Taylor, J., Berg, S., Smith, N. J., Kern, R., Picus, M., Hoyer, S., van Kerkwijk, M. H., Brett, M., Haldane, A., del Río, J. F., Wiebe, M., Peterson, P., … Oliphant, T. E. (2020). Array programming with NumPy. *Nature*, *585*(7825), 357–362. https://doi.org/10.1038/s41586-020-2649-2

Hunter, J. D. (2007). Matplotlib: A 2D Graphics Environment. *Computing in Science & Engineering*, *9*(3), 90–95. https://doi.org/10.1109/MCSE.2007.55

Kim, H. S., Kim, M. G., Min, K. W., Jung, U. S., & Kim, D. H. (2021). High MMP-11 expression associated with low CD8+ T cells decreases the survival rate in patients with breast cancer. *PLoS ONE*, *16*(5 May). https://doi.org/10.1371/journal.pone.0252052

Koboldt, D. C., Fulton, R. S., McLellan, M. D., Schmidt, H., Kalicki-Veizer, J., McMichael, J. F., Fulton, L. L., Dooling, D. J., Ding, L., Mardis, E. R., Wilson, R. K., Ally, A., Balasundaram, M., Butterfield, Y. S. N., Carlsen, R., Carter, C., Chu, A., Chuah, E., Chun, H. J. E., … Palchik, J. D. (2012). Comprehensive molecular portraits of human breast tumours. *Nature*, *490*(7418), 61–70. https://doi.org/10.1038/nature11412

Kuleshov, M. V., Jones, M. R., Rouillard, A. D., Fernandez, N. F., Duan, Q., Wang, Z., Koplev, S., Jenkins, S. L., Jagodnik, K. M., Lachmann, A., McDermott, M. G., Monteiro, C. D., Gundersen, G. W., & Ma'ayan, A. (2016). Enrichr: a comprehensive gene set enrichment analysis web server 2016 update. *Nucleic Acids Research*, *44*(W1), W90–W97. https://doi.org/10.1093/nar/gkw377

Love, M. I., Huber, W., & Anders, S. (2014). Moderated estimation of fold change and dispersion for RNA-seq data with DESeq2. *Genome Biology*, *15*(12), 550. https://doi.org/10.1186/s13059-014-0550-8

McKinney, W. (2010). Data Structures for Statistical Computing in Python. In Stefan van der Walt and Jarrod Millman (Ed.), *Proceedings of the 9th Python in Science Conference* (pp. 56–61). https://doi.org/10.25080/Majora-92bf1922-00a

Muzellec, B., Teleńczuk, M., Cabeli, V., & Andreux, M. (2023). PyDESeq2: a python package for bulk RNA-seq differential expression analysis. *Bioinformatics*, *39*(9). https://doi.org/10.1093/bioinformatics/btad547

Vargas, A. C., Reed, A. E. M. C., Waddell, N., Lane, A., Reid, L. E., Smart, C. E., Cocciardi, S., Da Silva, L., Song, S., Chenevix-Trench, G., Simpson, P. T., & Lakhani, S. R. (2012). Gene expression profiling of tumour epithelial and stromal compartments during breast cancer progression. *Breast Cancer Research and Treatment*, *135*(1), 153–165. https://doi.org/10.1007/s10549-012-2123-4

Yazdani, B., & Sirous, H. (2022). Expression analysis of HIF-3α as a potent prognostic biomarker in various types of human cancers: a case of meta-analysis. *Research in Pharmaceutical Sciences*, *17*(5), 508–526. https://doi.org/10.4103/1735-5362.355210

Yu, G., Wang, L.-G., Han, Y., & He, Q.-Y. (2012). clusterProfiler: an R Package for Comparing Biological Themes Among Gene Clusters. *OMICS: A Journal of Integrative Biology*, *16*(5), 284–287. https://doi.org/10.1089/omi.2011.0118

Zhu, Z., Wang, H., Qian, X., Xue, M., Sun, A., Yin, Y., Tang, J., & Zhang, J. (2024). Inhibitory Impact Of Cinobufagin In Triple-Negative Breast Cancer Metastasis: Involvements Of Macrophage Reprogramming Through Upregulated MME and Inactivated FAK/STAT3 Signaling. *Clinical Breast Cancer*, *24*(4), e244-e257.e1. https://doi.org/10.1016/j.clbc.2024.01.014

Zhuang, Y., Li, X., Zhan, P., Pi, G., & Wen, G. (2021). MMP11 promotes the proliferation and progression of breast cancer through stabilizing Smad2 protein. *Oncology Reports*, *45*(4). https://doi.org/10.3892/or.2021.7967